MACHINE LEARNING · RIESGO DE CRÉDITO

HOME CREDIT DEFAULT RISK

Competencia de ML de GCI World 2026 · Matsuo-Iwasawa Lab, UTokyo

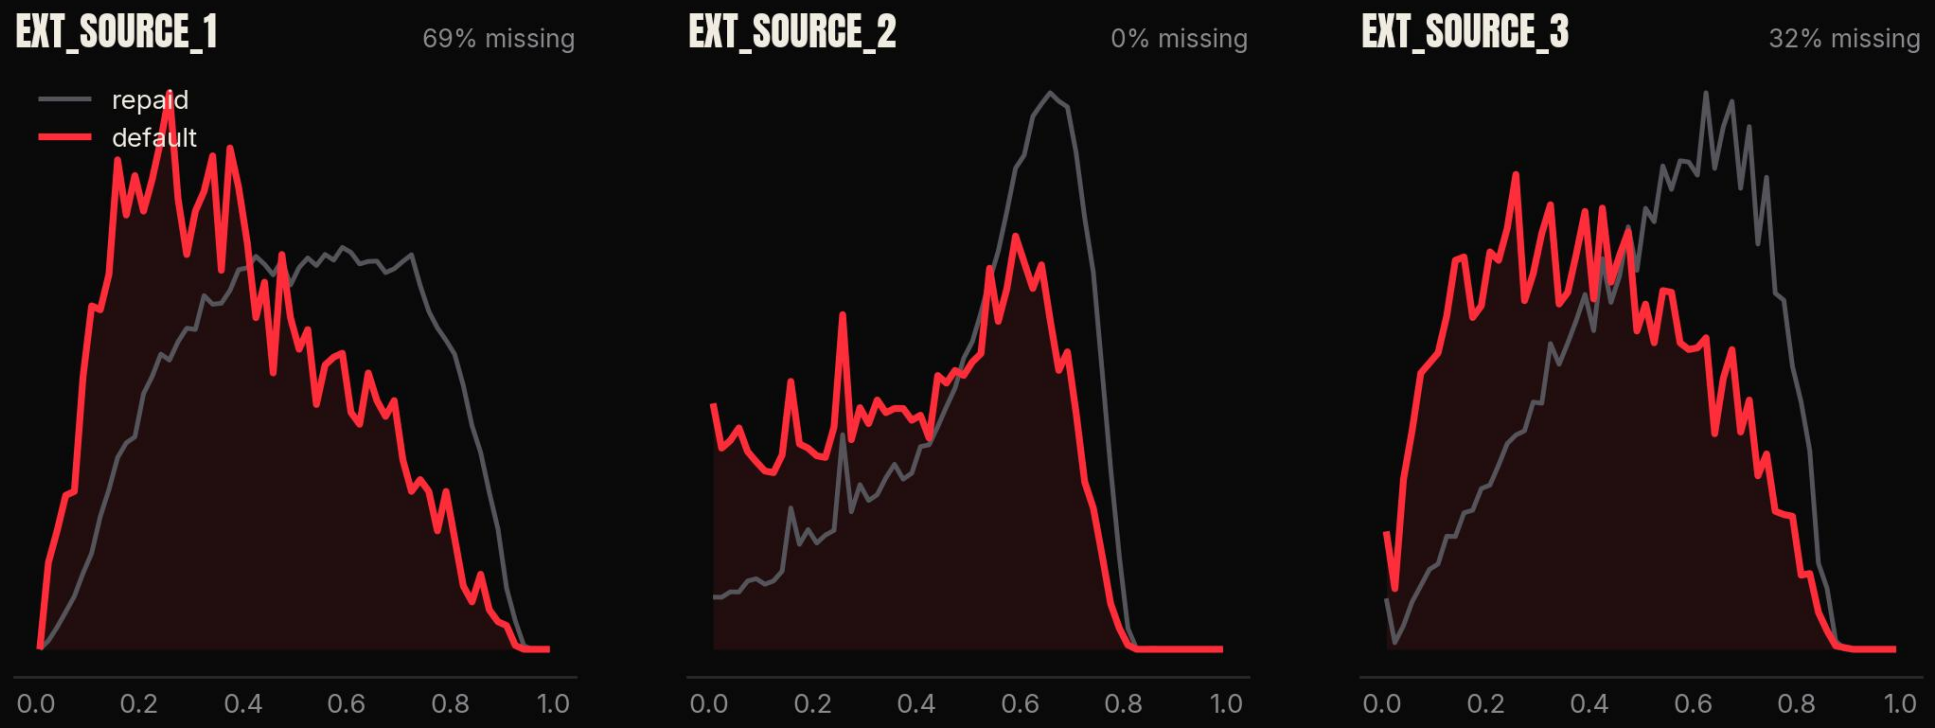
01

EL RETO

Predecir qué clientes no pagarán su crédito · 171,202 solicitudes · métrica ROC-AUC

LOS SCORES EXTERNOS SEPARAN A QUIEN NO PAGA

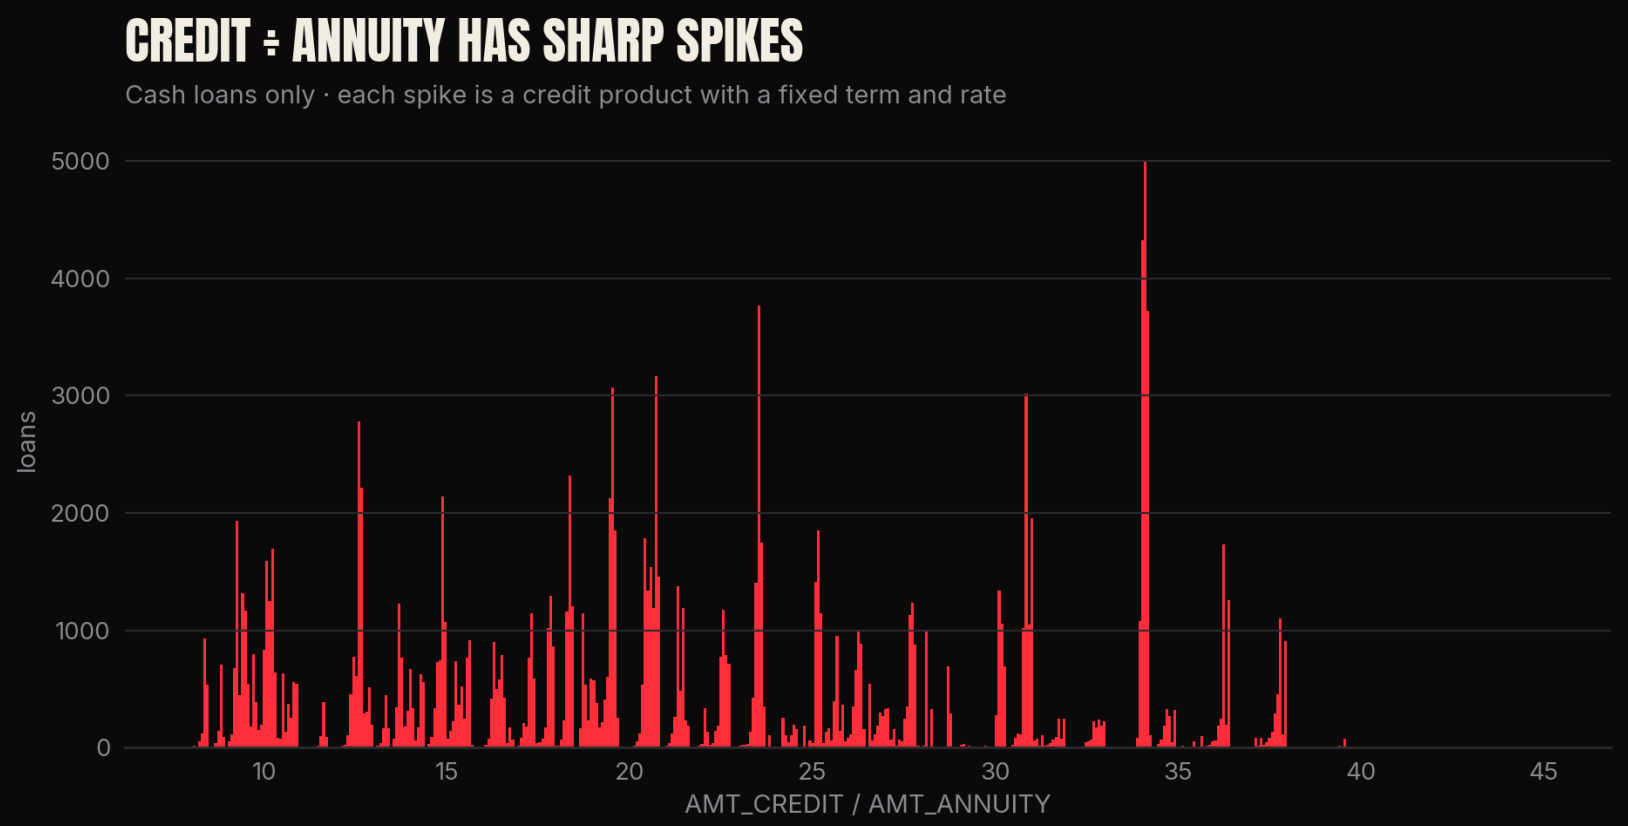
Quienes caen en impago (rojo) tienen scores sistemáticamente más bajos; pero a EXT_SOURCE_1 le falta casi el 70% de los datos, así que lo completé con un modelo.



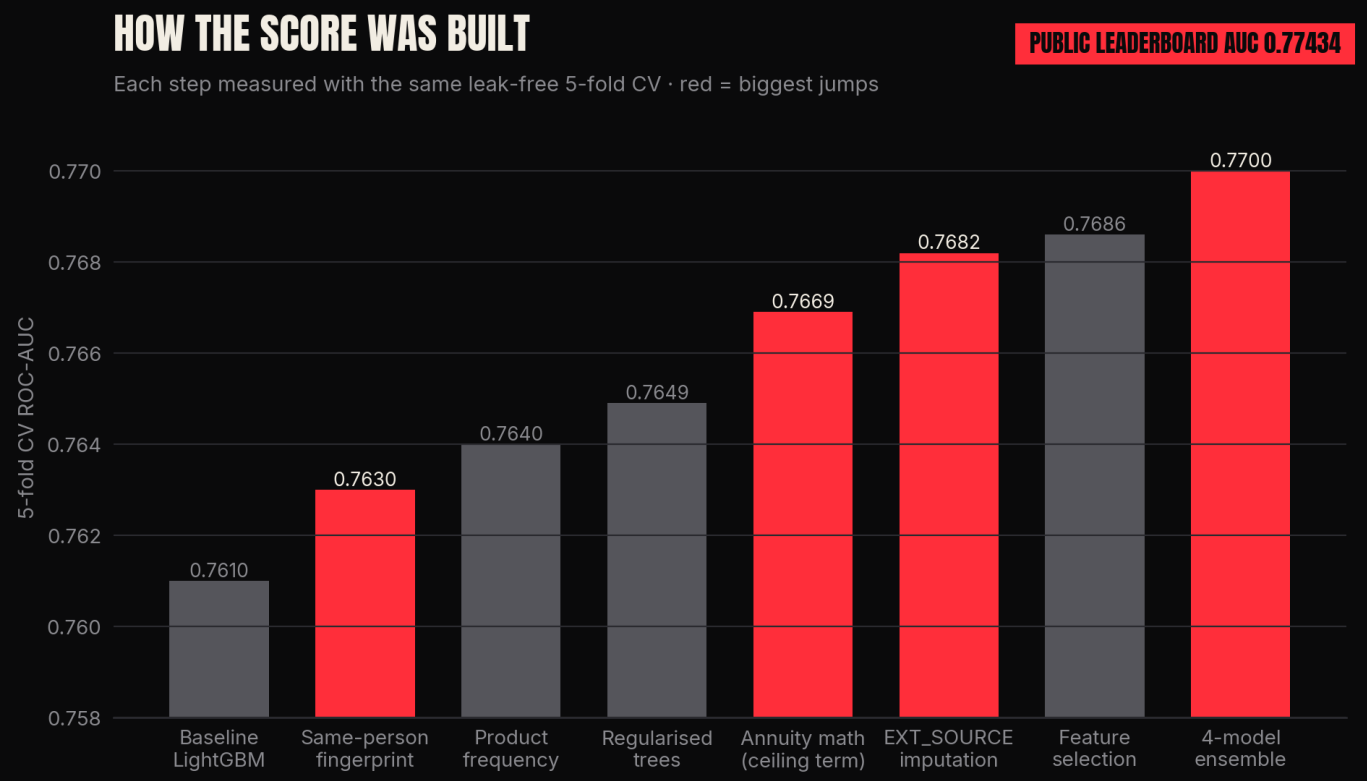
Defaulters (red) have systematically lower external scores · train set, 171,202 clients

CRÉDITO ÷ CUOTA TIENE PICOS

Cada pico es un producto de crédito con plazo y tasa fijos: la pista para recuperar la tasa de interés oculta.



CÓMO SE CONSTRUYÓ EL SCORE



GCI World 2026 · Matsuo-Iwasawa Lab, UTokyo

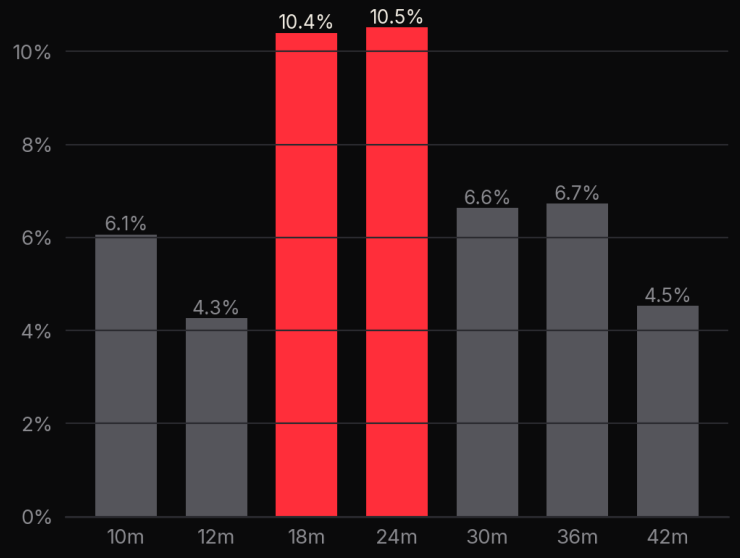
CONCLUSIÓN

Las dos mejores mejoras salieron de entender cómo se generan los datos, no de un modelo más complejo.

MATEMÁTICA DE ANUALIDADES

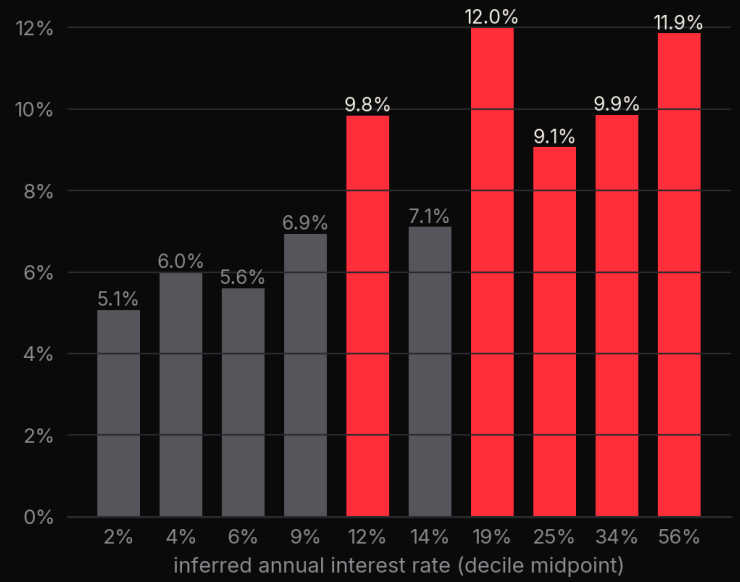
DEFAULT RATE BY INFERRED TERM

Shortest standard term longer than credit ÷ annuity



DEFAULT RATE BY INFERRED RATE

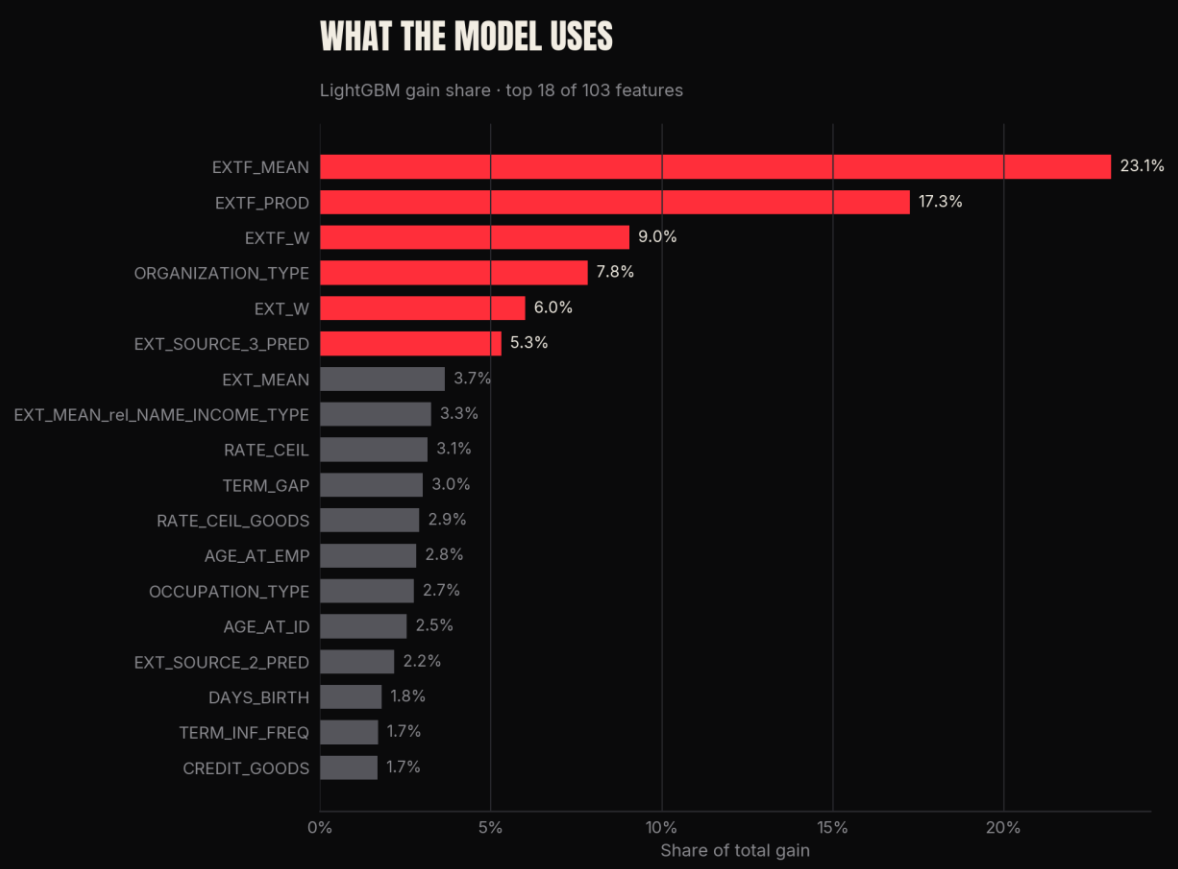
Solved by bisection from the annuity formula



CONCLUSIÓN

Despejar la fórmula de la cuota con bisección recupera el plazo y la tasa ocultos: los plazos de 18 y 24 meses tienen ~10% de impago.

QUÉ USA EL MODELO



CONCLUSIÓN

Los scores externos imputados y las variables de anualidad están entre las más usadas.

RESULTADOS

0.7743

AUC PÚBLICO

leaderboard de la competencia

0.7700

AUC EN CV

5 folds, sin fuga de datos

+0.009

VS. BASELINE

8 pasos medidos

LO QUE APRENDÍ

01 Entender cómo se generan los datos vale más que cambiar de modelo

02 Las matemáticas son una herramienta de feature engineering

03 Validar sin fuga es lo que permite confiar en el resultado

04 Documentar lo que no funcionó también es parte del trabajo

GRACIAS

linkedin.com/in/brandon-uriel-garcia-sanchez-9ab77b320

github.com/CatoXP